
§ 2 三角分解法 /* Matrix Factorization */

▶ 高斯消元法的矩阵形式 /* Matrix Form of G.E. */:


Step 1:
$$m_{i1} = a_{i1} / a_{11}$$
 $(a_{11} \neq 0)$

§ 2 Matrix Factorization – Matrix Form of G.E.



▶ 杜利特分解法 /* Doolittle Factorization */:

—— LU 分解的紧凑格式 /* compact form */





思 通过比较法直接导出L和U的计算公式。

$$\begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & & \vdots \\ a_{n1} & \dots & a_{nn} \end{bmatrix} = \begin{bmatrix} 1 & & & \\ l_{21} & 1 & & \\ \vdots & \dots & & \\ l_{n1} & \dots & 1 \end{bmatrix} \begin{bmatrix} u_{11} & \dots & u_{1n} \\ & \dots & \vdots \\ & & \vdots \\ & & u_{nn} \end{bmatrix}$$

$$\Rightarrow a_{ij} = \sum_{k=1}^{\min(i,j)} l_{ik} u_{kj}$$

 $l_{ii}=1$

$$a_{ij} = \sum_{k=1}^{\min(i,j)} l_{ik} u_{kj}$$

固定 i:

对
$$j = i, i+1, ..., n$$
 有 $a_{ij} = \sum_{k=1}^{i-1} l_{ik} u_{kj} + u_{ij}$

$$\Rightarrow u_{ij} = a_{ij} - \sum_{k=1}^{i-1} l_{ik} u_{kj}$$



将 i, j 对换,对 j = i, i+1, ..., n 一般采用列主元

$$\Rightarrow l_{ji} = (a_{ji} - \sum_{k=1}^{i-1} l_{jk} u_{ki}) / u_{ii}$$


法增强稳定性。但注意 **b** 也必须做相应的 行交换。

Algorithm: Doolittle Factorization

Step 1:
$$u_{1j} = a_{1j}$$
; $l_{j1} = a_{j1} / u_{11}$; $(j = 1, ..., n)$

Step 2: compute
$$(a)$$
 and (b) for $i = 2, ..., n-1$;

Step 3:
$$u_{nn} = a_{nn} - \sum_{k=1}^{n-1} l_{nk} u_{kn}$$



求解Ly=b,Ux=y的计算公式

$$\begin{cases} y_1 = b \\ y_i = b_i - \sum_{k=1}^{i-1} l_{ik} y_k \end{cases}$$
 i=2,3,...,n

$$\begin{cases} x_n = y_n / u_{nn} \\ x_i = (y_i - \sum_{k=i+1}^n u_{ik} x_k) / u_{ii} \end{cases} i = n-1, n-2, ..., 1$$

■选主元的三角分解法

直接三角分解法的局限性:

当urr=0时计算中断

当um绝对值很小时,引起舍入误差的累积。

设第r-1步分解已完成

	u_{11}	u_{12}	• • •	$u_{1,r-1}$	u_{1r}	• • •	u_{1n}
	l_{21}	u_{22}	• • •	$u_{2,r-1}$	u_{2r}	• • •	u_{2n}
	•	•		•	•		•
$A \rightarrow$	$l_{r-1,1}$	$l_{r-1,2}$	•••	$u_{r-1,r-1}$	$u_{r-1,r}$	• • •	$u_{r-1,n}$
	l_{r1}	l_{r2}	• • •	$l_{r,r-1}$	a_{rr}	• • •	a_m
	•	•		•	•		•
	l_{n1}	l_{n2}	• • •	$l_{n,r-1}$	a_{nr}	• • •	a_{nn}

直接LU分解的第r步分解

$$u_{ri} = a_{ri} - \sum_{k=1}^{r-1} l_{ik} u_{ki} \qquad i=r,r+1,...,n, \exists r \neq n$$

$$l_{ir} = (a_{ir} - \sum_{k=1}^{r-1} l_{ik} u_{kr}) / u_{rr} \qquad i=r+1,...,n, \exists r \neq n$$

为避免urr过小

$$S_i = a_{ir} - \sum_{k=1}^{r-1} l_{ik} u_{kr}$$
 (i=r,r+1,...,n)
 $u_{rr} = S_r$ $l_{ir} = S_i / S_r$ (i=r+1,...,n)

取 $\max_{r \le i \le n} |s_i| = |s_{i_r}|$ A的r行 \Leftrightarrow A的i_r行

$$S_{i_r} \rightarrow (r,r)$$

算法4(选主元的三角分解法)

$$PA = I_{n-1,i_{n-1}} \cdots I_{1,i_1} A = LU$$

Ip(n)记录主行

1.对于r=1,2,...,n

1) 计算
$$\mathbf{s_i}$$
 $a_{ir} \leftarrow s_i = a_{ir} - \sum_{k=1}^{r-1} l_{ik} u_{kr}$ (i=r,r+1,...,n)

- 2)选主元 $|s_{i_r}| = \max_{r \le i \le n} |s_i|$ $| Ip(r) \leftarrow i_r$
- 3)交换A的r行元素与 i_r 行元素 $a_{ri} \leftrightarrow a_{i_r,i}$
- 4)计算U的第r行元素,L的第r列元素

$$a_{rr} = u_{rr} = s_{r}$$

$$a_{ir} \leftarrow l_{ir} = s_{i} / u_{rr} = a_{ir} / a_{rr} \quad i = r+1, ..., n, \exists r \neq n$$

$$a_{ri} \leftarrow u_{ir} = a_{ri} - \sum_{k=1}^{r-1} l_{rk} u_{ki} \quad i = r+1, ..., n, \exists r \neq n$$

求解Ly=Pb及Ux=y

2.对于i=1,...,n-1

 $1)t \leftarrow Ip(i)$

2)若i=t则转3),否则 $b_i \leftrightarrow b_t$

3.
$$b_i \leftarrow b_i - \sum_{k=1}^{i-1} l_{ik} b_k$$
 (i=2,3,..,n)

解x存放在b中

4. $b_n \leftarrow b_n / u_{nn}, b_i \leftarrow (b_i - \sum_{k=i+1}^n u_{ik} b_k) / u_{ii} = n-1, ..., 1$

PA=LU
$$\longrightarrow$$
 $A^{-1} = U^{-1}L^{-1}P$

- 1)计算上三角矩阵的逆阵U-1
- 2)计算U-1L-1
- 3)交换U-1L-1的列

- ➤ 平方根法 /* Choleski's Method */:
 - 矩阵的分解法



一个矩阵 $A = (a_{ii})_{n \times n}$ 称为对称阵,如果 $a_{ii} = a_{ii}$ 。



一个矩阵 A 称为正定阵,如果 $\bar{x}^T A \bar{x} > 0$ 对任意非 零向量 x 都成立。

- □回顾: 对称正定阵的几个重要性质
- $+ A^{21}$ 亦对称正定,且 a_{ii} $\stackrel{?}{>}$ 0
- ◆ A 的顺序主子阵 /* leading principal submatrices */A_k 亦对 称正定
- 对任意 \bar{x} 对任意 \bar{x} \bar{x} $(0...1...0)^{T}$
- A 的全部顺序主子式det $(A_k) > 0$ \bar{r} . $\neq \bar{0} \in \mathbb{R}^k$ 有 设对应特征值的非零特征向量 $|\vec{x}| |\vec{x}|^2$

因为
$$\det(A) = \prod_{i=1}^{n} \lambda_i$$

将对称 正定阵 A 做 LU 分解

$$U = \begin{bmatrix} u_{ij} \\ u_{ij} \end{bmatrix} = \begin{bmatrix} u_{i1} \\ u_{i2} \end{bmatrix}$$
 $= \begin{bmatrix} u_{i1} \\ u_{i2} \end{bmatrix}$ $= \begin{bmatrix} u_{i1} \\ u_{in} \end{bmatrix}$ $= \begin{bmatrix} u_{i1} \\ u_{in} \end{bmatrix}$ $= \begin{bmatrix} u_{i1} \\ u_{i2} \end{bmatrix}$ $= \begin{bmatrix}$

注:对于对称正定阵A,从 $a_{ii} = \sum_{k=1}^{i} l_{ik}^2$ 可知对任意 $k \leq i$ 有 $|l_{ik}| \leq \sqrt{a_{ii}}$ 。即 L 的元素不会增大,误差可控,不需选主元。

$$A = \begin{bmatrix} l_{11} & l_{21} & \cdots & l_{n1} \\ l_{21} & l_{22} & \cdots & l_{n2} \\ \vdots & \vdots & \ddots & & \ddots & \vdots \\ l_{n1} & l_{n2} & \cdots & l_{nn} \end{bmatrix} \begin{bmatrix} l_{11} & l_{21} & \cdots & l_{n1} \\ l_{22} & \cdots & l_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ l_{nn} & l_{nn} \end{bmatrix}$$
 接列计算
$$a_{ij} = \sum_{k=1}^{n} l_{ik} l_{jk} = \sum_{k=1}^{j-1} l_{ik} l_{jk} + l_{jj} l_{ij}$$

Algorithm: Choleski's Method

To factor the symmetric positive definite $n \times n$ matrix A into LL^T , where L is lower triangular.

Input: the dimension n; entries a_{ij} for $1 \le i, j \le n$ of A.

Output: the entries l_{ii} for $1 \le j \le i$ and $1 \le j \le n$ of L.

Step 1 Set
$$l_{11} = \sqrt{a_{11}}$$
;

Step 2 For
$$j = 2, ..., n$$
, set 1

Step 3 Fo 因为A 对称,所以只需存半个A,即
$$A[n(n+1)/2] = \{a_{11}, a_{21}, a_{22}, ..., a_{n1}, ..., a_{nn}\}$$

其中
$$A[i\times(i-1)/2+j]$$

Step 6 Set 运算量为
$$O(n^3/6)$$
,比普通 LU

Step 7
$$\bigcirc$$
 分解少一半,但有 n 次开方。用 $A = LDL^T$ 分解,可省开方时间。

利用定理10, A=LDLT,避免开方运算

$$A = \begin{bmatrix} 1 & & & \\ l_{21} & 1 & & \\ \vdots & \vdots & \ddots & \\ \hline 按行计算 & \cdots & 1 \end{bmatrix} \begin{bmatrix} d_1 & & & \\ d_2 & & & \\ & \ddots & \vdots & \\ & & \ddots & \vdots \\ & & & d_n \end{bmatrix} \begin{bmatrix} 1 & l_{21} & \cdots & l_{n1} \\ 1 & \cdots & l_{n2} \\ & \ddots & \vdots \\ & & & \ddots & \vdots \\ & & & & 1 \end{bmatrix}$$

$$a_{ij} = \sum_{k=1}^{n} (LD)_{ik} (L^T)_{kj} = \sum_{k=1}^{n} l_{ik} d_k l_{jk} = \sum_{k=1}^{j-1} l_{ik} d_k l_{jk} + l_{ij} d_j l_{jj}$$

$$x + \mathbf{fi} = \mathbf{1}, \mathbf{2}, \dots, \mathbf{n}$$

$$l_{ij} = (a_{ij} - \sum_{k=1}^{j-1} l_{ik} d_j l_{jk}) / a_j = \mathbf{1}, \mathbf{2}, \dots, \mathbf{i} - 1$$

$$d_i = a_{ii} - \sum_{k=1}^{i-1} l_{ik}^2 d_k$$

> 改进的平方根法

对于i=2,3,...,n

1
$$t_{ij} = a_{ij} - \sum_{k=1}^{j-1} t_{ik} l_{jk}$$
 j=1,2,...,i-1

$$2 \quad l_{ij} = t_{ij} / d_j$$

$$3 d_i = a_{ii} - \sum_{k=1}^{i-1} t_{ik} l_{ik}$$


求解Ly=b,DLTx=y

$$\begin{cases}
y_{1} = b_{1} \\
y_{i} = b_{i} - \sum_{k=1}^{i-1} l_{ik} y_{k} \quad (i = 2, ..., n)
\end{cases}$$

$$\begin{cases}
x_{n} = y_{n} / d_{n} \\
x_{i} = y_{i} / d_{i} - \sum_{k=i+1}^{n} l_{ki} x_{k} \quad (i = n-1, ..., 2, 1)
\end{cases}$$

▶ 追赶法解三对角方程组

/* Crout Reduction for Tridiagonal Linear System */



Step 2: 追 即解
$$L \bar{y} = \bar{f}$$
: $y_1 = \frac{f_1}{\alpha_1}$, $y_i = \frac{(f_i - r_i y_{i-1})}{\alpha_i}$ $(i = 2, ..., n)$

Step 3: 赶——即解
$$U \bar{x} = \bar{y}$$
: $x_n = y_n$, $x_i = y_i - \beta_i x_{i+1}$ $(i = n-1, ..., 1)$

定理 若 A 为对角占优 /* diagonally dominant */ 的三对角阵,且满足 $|b_1|>|c_1|>0$, $|b_n|>|a_n|>0$, $a_i\neq 0$, $c_i\neq 0$,则追赶 法可解以 A 为系数矩阵的方程组。

证明:由
$$\alpha_1 = b_1 \neq 0$$

$$|b_1| > |c_1| > 0$$

$$\beta_1 = c_1/b_1$$

用归纳法证明 $|\alpha_i| > |c_i| \neq 0$ i=1,2,...,n-1 $0 < |\beta_i| < 1$ 从而可求出 \mathbf{B} i=1时,显然成立。假设对 \mathbf{i} 成立。

由归纳法假设, $0 < |\beta_{i-1}| < 1$

$$|\alpha_i| = |b_i - a_i \beta_{i-1}| \ge |b_i| - |a_i \beta_{i-1}| > |b_i| - |a_i| \ge |c_i| \ne 0$$

注:

- ☞ 如果 A 是严格对角占优阵,则不要求三对角线上的 所有元素非零。
- ☞ 根据不等式 $|\beta_i| < 1$, $|b_i| |a_i| < |b_i \gamma_i \beta_{i-1}| < |b_i| + |a_i|$ 可知:分解过程中,矩阵元素不会过分增大,算法 保证稳定。
- ☞ 运算量为 O(6n)。

§ 5.5 向量和矩阵范数 /* Norms of Vectors and Matrices */

——为了误差的度量

定义1:
$$\mathbf{x}, \mathbf{y} \in \mathbf{R}_{n}$$
, 将 $(x, y) = y^{T} x = \sum_{i=1}^{n} x_{i} y_{i}$

称为向量x,y的数量积。

将 $\|x\|_2 = (x,x)^{\frac{1}{2}} = (\sum_{i=1}^n x_i^2)^{\frac{1}{2}}$ 称为向量x的欧氏范粉

定理13 设x,y ∈ Rⁿ,则

$$(x,x)=0$$
 \longrightarrow $x=0$

$$(ax,y)=a(x,y)$$

$$(x,y)=(y,x)$$

$$(x_1+x_2,y)=(x_1,y)+(x_2,y)$$

Cauchy-Schwarz 不等式

$$|(x,y)| \le |x|_2 ||y||_2$$

$$||x + y||_2 \le ||x||_2 + ||y||_2$$


三角不等式


▶ 向量范数 /* vector norms */

定义 R^n 空间的向量范数 $\|\cdot\|$ 对任意 $\bar{x}, \bar{y} \in R^n$ 满足下列条件:

- (1) $\|\vec{x}\| \ge 0$; $\|\vec{x}\| = 0 \Leftrightarrow \vec{x} = \vec{0}$ (正定性/* positive definite */)
- (2) $\|\alpha \vec{x}\| = |\alpha| \cdot \|\vec{x}\|$ 对任意 $\alpha \in C$ (齐次性/* homogeneous */)
- (3) $\|\vec{x} + \vec{y}\| \le \|\vec{x}\| + \|\vec{y}\|$ (三角不等式 /* triangle inequality */)

 $||x|| - ||y|| \le ||x - y||$





$$\left\| \vec{x} \right\|_{2} = \sqrt{\sum_{i=1}^{n} \left| x_{i} \right|^{2}}$$

$$\left\| \vec{x} \right\|_{p} = \left(\sum_{i=1}^{n} |x_{i}|^{p} \right)^{1/p}$$

$$\| \vec{x} \|_{\infty} = \max_{1 \le i \le n} |x_i|$$

注:
$$\lim_{p\to\infty} \|\vec{x}\|_p = \|\vec{x}\|_\infty$$

定义 向量序列 $\{\bar{x}^{(k)}\}$ 收敛于向量 $\bar{x}*$ 是指对每一个 $1 \le i \le n$ 都 有 $\lim_{k\to\infty} x_i^{(k)} = x_i^*$ 。 可以理解为 $\|\bar{x}^{(k)} - \bar{x}^*\|_{\infty} \to 0$ 定理14 (N(x)的连续性) 设非负函数N(x)= $\|x\|$ 为Rⁿ上任一向

量范数,则N(x)是x的分量x1,x2,...,xn的连续函数。证明见P199

定理15 Rn 上一切范数都等价。

可以理解为对任何 向量范数都成立。

证明: 只要证明

$$c_1 \|x\|_{\infty} \le \|x\|_{t} \le c_2 \|x\|_{\infty}$$

有界闭集 $x \in \mathbb{R}^n$

$$x \in \mathbb{R}^n$$

记
$$S = \{x \mid ||x||_{\infty} = 1, x \in \mathbb{R}^n\}$$

若能证明向量序列在 一种范数意义下向量 序列收敛,则在任何 一种范数意义下该向 量序列均收敛。

由于f(x)是S上的连续函数,所以f(x)在S上有最大最小值,即

$$f(x') = \min_{x \in S} f(x) = c_1$$
 $f(x'') = \max_{x \in S} f(x) = c_2$

设 $\mathbf{x} \in \mathbb{R}^n$ 且 $\mathbf{x} \neq \mathbf{0}$,则 $\frac{x}{\|x\|} \in S$

$$\frac{x}{\|x\|_{\infty}} \in S$$

$$c_1 \le f(\frac{x}{\|x\|_{\infty}}) \le c_2 \qquad \longrightarrow \qquad c_1 \le \left\| \frac{x}{\|x\|_{\infty}} \right\|_t \le c_2$$

$$c_1 \le \left\| \frac{x}{\|x\|_{\infty}} \right\|_t$$

定理15不能推广到无 穷维空间

$$\left\| \overline{\|x\|_{\infty}} \right\|_{t} \leq c_{2}$$

$$c_1 \|x\|_{\infty} \le \|x\|_t \le c_2 \|x\|_{\infty}$$

定理16
$$\lim_{k \to \infty} x^{(k)} = x * \iff \lim_{k \to \infty} \left\| x^{(k)} - x * \right\| = 0$$

证明:显然
$$\lim_{k \to \infty} x^{(k)} = x^* \implies \lim_{k \to \infty} ||x^{(k)} - x^*|| = 0$$

对于 R^n 上的任何一种范数|| ||,由定理15,存在常数 $c_1,c_2>0$

$$c_1 \left\| x^{(k)} - x * \right\|_{\infty} \le \left\| x^{(k)} - x * \right\| \le c_2 \left\| x^{(k)} - x * \right\|_{\infty}$$

$$\lim_{k \to \infty} ||x^{(k)} - x^*||_{\infty} = 0 \implies \lim_{k \to \infty} x^{(k)} = x^*$$

➤ 矩阵范数 /* matrix norms */

定义 Rm×n空间的矩阵范数 ||·||对任意 A,B∈Rm×n 满足:

- (1) $||A|| \ge 0$; $||A|| = 0 \Leftrightarrow A = 0$ (正定性/* positive definite */)
- (2) $\|\alpha A\| = |\alpha| \cdot \|A\|$ 对任意 $\alpha \in C$ (齐次性 /* homogeneous */)
- (3) $||A+B|| \le ||A|| + ||B||$ (三角不等式 /* triangle inequality */)
- $(4)* ||AB|| \le ||A|| \cdot ||B||$ (相容 /* consistent */ 当 m = n 时)



🦖 常用矩阵范数:

Frobenius 范数
$$||A||_F = \sqrt{\sum_{i=1}^n \sum_{j=1}^n |a_{ij}|^2}$$
 一 向量 $||\cdot||_2$ 的直接推广

对方阵 $A \in \mathbb{R}^{n \times n}$ 以及 $\bar{x} \in \mathbb{R}^n$ 有 $||A\bar{x}||_2 \leq ||A||_F \cdot ||\bar{x}||_2$

算子范数 /* operator norm */

由向量范数
$$\|\cdot\|_p$$
 导出关于矩陣 $\text{Qauchy} \text{**n}$ 箭式 数: $|\bar{x}\cdot\bar{y}| \leq \|\bar{x}\|_{2,j} \|\bar{y}\|_{2}$ 可证。 $\|A\bar{x}\|_{p} = \max_{\bar{x}\neq\bar{0}} \frac{\|A\bar{x}\|_{p}}{\|\bar{x}\|} = \text{矩阵 } A^TA \text{ 的最大} \quad \|_{p} \leq \|A\|_{p} \|\bar{x}\|_{p}$

特征根 /* eigenvalue */

特别有:
$$||A||_{\infty} = \max_{1 \le i \le n}$$

$$||A||_2 = \sqrt{\lambda_{\text{max}}} (A^T A)$$
 (in the spectral norm */)

定理17 设||x||_v是Rⁿ上一个向量范数,则||A||_v是R^{n×n}上的矩 阵范数, 且满足相容条件

证明:
$$\|Ax\|_{v} \leq \|A\|_{v} \|x\|_{v}$$

$$\|A\|_{v} = \max_{x \neq 0} \frac{\|Ax\|_{v}}{\|x\|_{v}} \Rightarrow \|A\|_{v} = \max_{x \neq 0} \frac{\|Ax\|_{v}}{\|x\|_{v}} \geq \frac{\|Ax\|_{v}}{\|x\|_{v}}$$

$$\|Ax\|_{v} \leq \|A\|_{v} \|x\|_{v}$$

容易证明,由向量范数诱导的矩阵范数符合定义1),2),3),下 面证明4)

$$||ABx||_{v} \le ||A||_{v} ||Bx||_{v} \le ||A||_{v} ||B||_{v} ||x||_{v}$$

当
$$\mathbf{x}$$
≠ $\mathbf{0}$ 时,有 $\frac{\|ABx\|}{\|x\|}$

$$\frac{\|ABx\|_{v}}{\|x\|_{v}} \le \|A\|_{v} \|B\|_{v}$$

当
$$\mathbf{x} \neq \mathbf{0}$$
时,有
$$\frac{\|ABx\|_{v}}{\|x\|_{v}} \leq \|A\|_{v} \|B\|_{v}$$

$$\|AB\|_{v} = \max_{x \neq 0} \frac{\|ABx\|_{v}}{\|x\|_{v}} \leq \|A\|_{v} \|B\|_{v}$$

证明 1)
$$||A||_{\infty} = \max_{1 \le i \le n} \sum_{j=1}^{n} |a_{ij}|$$

谈 $x=(x_1,x_2,...,x_n)^T \neq 0, A \neq 0.$

$$t = ||x||_{\infty} = \max_{1 \le i \le n} |x_i|$$
 $\mu = \max_{1 \le i \le n} \sum_{j=1}^{n} |a_{ij}|$

$$||Ax||_{\infty} = \max_{1 \le i \le n} |\sum_{j=1}^{n} a_{ij} x_{j}| \le \max_{i} \sum_{j=1}^{n} |a_{ij}| |x_{j}| \le t \max_{i} \sum_{i=1}^{n} |a_{ij}|$$

$$\frac{||Ax||_{\infty}}{||x||_{\infty}} \le \mu$$

下面说明存在向量 $\mathbf{x_0} \neq \mathbf{0}$,使 $\frac{\|Ax\|_{\infty}}{\|x\|_{\infty}} = \mu$

设
$$\mu = \sum_{j=1}^{n} |a_{i_0 j}|$$
 取向量 $\mathbf{x_0} = (\mathbf{x_1}, \mathbf{x_2}, ..., \mathbf{x_n})^{\mathrm{T}}$,其中

$$x_j = \operatorname{sgn}(a_{i_0 j}), (j = 1, 2, ..., n)$$

显然 $\|x_0\|_{\infty} = 1$ $\mathbf{A}\mathbf{x_0}$ 的第 $\mathbf{i_0}$ 个分量为



$$\sum_{i=1}^{n} a_{i_0 j} x_j = \sum_{j=1}^{n} |a_{i_0 j}|$$

$$\sum_{i=1}^{n} a_{i_0 j} x_j = \sum_{j=1}^{n} |a_{i_0 j}|$$

$$\|Ax_0\|_{\infty} = \max_{1 \le i \le n} |\sum_{j=1}^{n} a_{ij} x_j| = \sum_{j=1}^{n} |a_{i_0 j}| = \mu$$

2)
$$\|A\|_2 = \sqrt{\lambda_{\max}(A^T A)}$$
 対称阵

当x=u₁时,

$$||Ax||_{2}^{2} = (Ax, Ax) = (A^{T}Ax, x) \ge 0$$

 $\|Ax\|_{2}^{2} = (Ax, Ax) = (A^{T}Ax, x) \ge 0 \qquad \lambda_{1} \ge \lambda_{2} \ge \cdots \ge \lambda_{n}$ $\exists u_{1}, u_{2}, \dots, u_{n} \Rightarrow A^{T}A \Rightarrow \text{ then } \text{ th$

$$\forall x \in R^n \quad x = \sum_{i=1}^n c_i u_i$$


$$||A||_2 = \max_{x \neq 0} \frac{||Ax||_2}{||x||_2} = \sqrt{\lambda_1} = \sqrt{\lambda_{\max}(A^T A)}$$

3)
$$\|A\|_{1} = \max_{1 \le j \le n} \sum_{i=1}^{n} |a_{ij}|$$

 $\exists A = [a_{1}, a_{2}, \dots, a_{n}] \qquad a_{j} = [a_{1j}, a_{2j}, \dots, a_{nj}]^{T}$
 $\max_{1 \le j \le n} \sum_{i=1}^{n} |a_{ij}| = \max_{1 \le j \le n} \|a_{j}\|_{1}$
 $\forall x = [x_{1}, x_{2}, \dots x_{n}]^{T} \in \mathbb{R}^{n}$
 $\|Ax\|_{1} = \|x_{1}a_{1} + x_{2}a_{2} + \dots + x_{n}a_{n}\|_{1} \le |x_{1}| \|a_{1}\|_{1} + \dots + |x_{n}| \|a_{n}\|_{1}$
 $\le (|x_{1}| + |x_{2}| + \dots + |x_{n}|) \max_{1 \le j \le n} \|a_{j}\|_{1} = \|x\|_{1} \max_{1 \le j \le n} \|a_{j}\|_{1}$
 $\frac{\|Ax\|_{1}}{\|x\|_{1}} \le \max_{1 \le j \le n} \|a_{j}\|_{1}$

若 $\max_{1 \le j \le n} ||a_j||_1 = ||a_k||_1$ 取 $x = e_k$,能使等号成立, $||e_k||_1 = 1$,


$$||Ae_k||_1 = ||a_k||_1 = \max_{1 \le j \le n} ||a_j||_1 = \max_{1 \le j \le n} \sum_{i=1}^n |a_{ij}||_1$$



- 罗 我们只关心有相邻
- 即使A中元素全为 /* eigenvector */ 仍可能 成复数模均成立。

性的范数, 算子范数总是相容的。 数, 其特征根和相应特征向量

数。将上述定义中绝对值换



定理

对任意算子范数 $\|\cdot\|$ 有 $\rho(A) \leq \|A\|$

证明:由算子范数的相容性,得到 $||A\bar{x}|| \le ||A|| \cdot ||\bar{x}||$ 将任意一个特征根 λ 所对应的特征向量 \bar{u} 代入 $||\lambda|| \cdot ||\bar{u}|| = ||\lambda\bar{u}|| = ||A\bar{u}|| \le ||A|| \cdot ||\bar{u}||$

定理

若A对称,则有 $||A||_2 = \rho(A)$

证明: $||A||_2 = \sqrt{\lambda_{\max}(A^T A)} = \sqrt{\lambda_{\max}(A^2)}$

A对称

若A是A的一个特征根

则 λ^2 必是 A^2 的特征根。

 $\Rightarrow \lambda_{\max}(A^2) = \lambda^2(A)$

ド个A的特征根λ成立

又:对称矩阵战业

即 $\lambda^2(A)$ 为非负实

数,

所以2-范数亦称为

谱范数。

故得证。

定理 若矩阵 B 对某个算子范数满足 |B|| < 1,则必有

①
$$I \pm B$$
 可逆; ② $||(I \pm B)^{-1}|| \leq \frac{1}{1-||B||}$

证明: ① 若不然,则 $(I\pm B)\bar{x}=\bar{0}$ 有非零解,即存在非零向

(2)
$$(I \pm B)^{-1} \pm B(I \pm B)^{-1} = (I \pm B)(I \pm B)^{-1} = I$$

$$\Rightarrow (I \pm B)^{-1} = I \mp B(I \pm B)^{-1}$$

$$\Rightarrow \| (I \pm B)^{-1} \| \le 1 + \| B \| \cdot \| (I \pm B)^{-1} \|$$

§ 5.6 线性方程组的误差分析

/* Error Analysis for Linear system of Equations */



(3) 求解 $A\bar{x} = \bar{b}$ 时, $A \to \bar{b}$ 的误差对解 \bar{x} 有何影响?

 \triangleright 设A精确, \bar{b} 有误差 $\delta\bar{b}$, 得到的解为 $\bar{x}+\delta\bar{x}$, 即

$$A(\bar{x} + \delta \, \bar{x}) = \vec{b} + \delta \, \vec{b}$$

绝对误差放大因子

$$\Rightarrow \delta \, \bar{x} = A^{-1} \, \delta \, \bar{b} \qquad \Rightarrow \| \delta \, \bar{x} \| \leq 1$$

$$\Rightarrow \|\delta \bar{x}\| \leq \|A - b\| \|\Delta \bar{x}\|$$

相对误差放大因子

$$\mathcal{Z} \parallel \vec{b} \parallel = \parallel A\vec{x} \parallel \leq \parallel A \parallel \cdot \parallel \vec{x} \parallel \qquad \Rightarrow \qquad \qquad \parallel \vec{b} \parallel$$

定理22

$$\frac{\parallel \delta |\vec{x} \parallel}{\parallel \vec{x} \parallel} \leq (\parallel A \parallel \cdot \parallel A^{-1} \parallel) \cdot \frac{\parallel \delta |\vec{b} \parallel}{\parallel \vec{b} \parallel}$$

 \triangleright 设 \bar{b} 精确. $||A|| \cdot ||A^{-1}||$ 是关键 7 为 $\bar{x} + \delta \bar{x}$,即



的误差放大因子,称为A的条件数,记为cond(A),越大 则A越病态,

 $A(\bar{x} + \delta \bar{x}) + \delta A(x)$ 难得准确解。

$$\Rightarrow \delta \bar{x} = -A^{-1} \delta A \left(1 + \delta \bar{x} \right)$$

$$\Rightarrow \frac{\|\delta \vec{x}\|}{\|\vec{x} + \delta \vec{x}\|} \leq \|A^{-1}\| \cdot \|\delta A\|$$

定理23 =
$$||A|| \cdot ||A^{-1}||$$
 $\frac{||\delta A||}{||A||}$

$$(A + \delta A)\bar{x} + (A + \delta A)\delta\bar{x} = \bar{b}$$

$$\Rightarrow (A + \delta A)\delta\bar{x} = -\delta A\bar{x}$$

$$\Rightarrow A(I + A^{-1}\delta A)\delta\bar{x} = -\delta A\bar{x}$$

$$= \delta\bar{x} = -(I + A^{-1}\delta A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\delta A\bar{x}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}A^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A} \oplus \delta A\bar{\lambda} + \mathbf{A} \oplus A)^{-1}\bar{\lambda} A\bar{\lambda}$$

$$(\mathbf{A}$$

$$\Rightarrow \frac{\delta \vec{x} \parallel}{\parallel \vec{x} \parallel} \leq \frac{\parallel A^{-1} \parallel \cdot \parallel \delta A \parallel}{1 - \parallel A^{-1} \parallel \cdot \parallel \delta A \parallel} =$$

注: © cond (A) 的具体大小与 ||·|| 的取法有关,但相对 大小一致。

☞ cond(A)取决于A,与解题方法无关。

$$\frac{\| \delta \vec{x} \|}{\| \vec{x} \|} \leq \frac{cond (A)}{1 - cond (A) \| \delta A \| / \| A \|} \left(\frac{\| \delta A \|}{\| A \|} + \frac{\| \delta \vec{b} \|}{\| \vec{b} \|} \right)$$

常用条件数有:

$$cond(A)_1$$

$$cond(A)_{\infty}$$

$$cond(A)_2$$

$$cond(A)_1$$
 $cond(A)_{\infty}$ $cond(A)_2$ $=\sqrt{\lambda_{\max}(A^TA)/\lambda_{\min}(A^TA)}$

特别地,若 A 对称,则 $cond(A)_2 = \frac{\max |\lambda|}{\min |\lambda|}$

条件数的性质:

- $\blacksquare A$ 可逆,则 $cond(A)_p \ge 1$;
- A正交,则 cond (A)₂=1;
- 圖 A可逆,R正交,则 $cond(RA)_2 = cond(AR)_2 = cond(A)_2$ 。

§ 2 Error Analysis for $A\vec{x} = \vec{b}$.

例:
$$A = \begin{pmatrix} 1 & 0.99 \\ 0.99 & 0.98 \end{pmatrix}$$
 , $\vec{b} = \begin{pmatrix} 1.99 \\ 1.97 \end{pmatrix}$ 精确解为 $\vec{x} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$. 计算 $cond(A)_2$ 。
$$A^{-1} = \begin{pmatrix} -9800 \\ 9900 \end{pmatrix}$$

$$A^{-1} = \begin{pmatrix} -9800 & 9900 \\ 9900 & -10000 \end{pmatrix}$$

解: 考察A 的特征根

$$\det(\lambda I - A) = 0 \implies \lambda_1 = 1.980050504$$

$$\lambda_2 = -0.000050504$$

$$cond(A)_2 = \left| \frac{\lambda_1}{\lambda_2} \right| \approx 39206 >> 1$$

$$cond (A)_2 = \left| \frac{\lambda_1}{\lambda_2} \right| \approx 39206 >> 1$$

测试病态程度:

给
$$\vec{b}$$
 一个扰动 $\delta \vec{b} = \begin{pmatrix} -0.97 \times 10^{-4} \\ 0.106 \times 10^{-3} \end{pmatrix}$, 其相对误差为

$$\frac{\|\delta \vec{b}\|_{2}}{\|\vec{b}\|_{2}} \approx 0.513 \times 10^{-4} < 0.01\%$$
 此时精确解为 $\vec{x}^{*} = \begin{pmatrix} 3 \\ -1.0203 \end{pmatrix}$

$$\delta \overline{x} = \overline{x} * - \overline{x} = \begin{pmatrix} 2 \\ -2.0203 \end{pmatrix} \implies \frac{\|\delta \overline{x}\|_2}{\|\overline{x}\|_2} \approx 2.0102 > 200\%$$

例: Hilbert 阵
$$H_n = \begin{bmatrix} 1 & \frac{1}{2} & \cdots & \frac{1}{n} \\ \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{n} \\ \frac{1}{2} & \frac{1}{3} & \cdots & \frac{1}{2n-1} \end{bmatrix}$$

$$cond(H_2) = 27 \qquad cond(H_2)$$

$$cond (H_2)_{\infty} = 27$$
 $cond (H_3)_{\infty} \approx 748$

$$cond (H_3)_{\infty} \approx 748$$

$$cond\ (H_6)_{\infty} = 2.9 \times 10^6 \quad cond\ (H_n)_{\infty} \to \infty \text{ as } n \to \infty$$

$$cond (H_n)_{\infty} \to \infty \text{ as } n \to \infty$$

- 注:一般判断矩阵是否病态,并不计算A-1,而由经验 得出。
 - ☞ 行列式很大或很小(如某些行、列近似相 关);
 - ☞ 元素间相差大数量级, 且无规则;
 - ☞ 主元消去过程中出现小主元;
 - 罗 特征值相差大数量级。

对于病态方程组可采用高精度的算术运算或采用预处理方法,即

$$\begin{cases} PAQy = Pb \\ y = Q^{-1}x \end{cases}$$

选择非奇异阵P,Q使 cond(PAQ)<cond 条件数得到改

不能保证A的

当矩阵A的元素大小不均时,对A的行(或列)引进当的比例 因子,对A的条件 作为第一行的比例因子

$$A^{-1} = \frac{1}{10^{4} - 1} \begin{bmatrix} x_{1} \\ x_{2} \end{bmatrix} = \begin{bmatrix} 10^{4} \\ 2 \end{bmatrix}$$

$$cond(A)_{\infty} = \frac{(1+10^4)^2}{10^4-1} \approx 10^4$$

$$x = (0,1)$$

例如
$$\begin{bmatrix} 1 & 10^4 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 10^4 \\ 2 \end{bmatrix}$$
 计算 $\begin{bmatrix} 10^{-4} & 1 \\ 2 \end{bmatrix} \begin{bmatrix} x_1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$

$$A'^{-1} = \frac{1}{1 - 10^{-4}} \begin{bmatrix} -1 & 1\\ 1 & -10^{-4} \end{bmatrix}$$

$$cond(A')_{\infty} = \frac{1}{1 - 10^{-4}} \approx 4$$

$$x = (1,1)$$

▶ 近似解的误差 定理24(事后误差估计)

设
$$A\bar{x} = \bar{b}$$
 的近似解 "如 $r = b - A\bar{x}^* \neq \bar{0}$

$$\Rightarrow \frac{\|\vec{x} - \vec{x}^*\|}{\|\vec{x}\|} \leq \frac{|\vec{r}|}{|\vec{b}|}$$

🛠 改善方法:

Step 1: $A\bar{x} = \vec{b} \Rightarrow$ 近似解 \bar{x}_1 ;

Step 2:
$$\vec{r}_1 = \vec{b} - A \vec{x}_1$$
;

Step 3:
$$A\vec{d}_1 = \vec{r}_1 \Rightarrow \vec{d}_1$$

Step 4:
$$\vec{x}_2 = \vec{x}_1 + \vec{d}_1$$
;

程美上限

若 d_1 可被精确解出,则有

$$\vec{x}_2 = \vec{x}_1 + A^{-1}(\vec{b} - A\vec{x}_1) = A^{-1}\vec{b}$$

 \bar{x}_2 就是精确解了。

经验表明: 若A 不是非常病态 (例如: ε ·cond (A)_∞ < 1),则如此迭代可达到机器精度;但若A 病态,则此算法也不能改进。